DeReFusion 代码库术语释义、公式解读与实验方法报告

Applied Soft Computing 研究项目

依据仓库快照 `Alastair-Jiang/DeReFusion`，分支 `main`，提交 `87bc113`（2026-10-13）

摘要—本报告整理并重写了前期形成的两份术语文档，面向需要对本项目进行说明与答辩的读者，系统给出三类内容：其一，本项目涉及的名词释义，以及每个名词在代码库中的确切位置；其二，对代码库中若干关键计算式的解读，特别是分解、归一化、残差分支与融合算子四组公式的数学含义及其实现细节；其三，实验方法层面的完整梳理，包括评估与统计判定体系、消融实验的全过程证据、以及由 L0–L5 六层卡口、执行授权与收据构成的治理制度。报告中同时列出该仓库已知的口径不一致与证据缺口。需要明确：本报告为术语与方法说明，不是实验报告，不构成任何结果发布、数据授权或执行许可。

索引词—金融时间序列预测；分解–残差架构；可逆实例归一化；融合策略；受控比较；预注册

I. 背景与范围

A. 三个需要区分的主体

讨论本项目时，以下三个主体必须分开陈述，混用会导致引用与责任归属错误。

原论文。 Chih-Chien Hsieh 与 Mu-Yen Chen（通讯作者），台湾成功大学工程科学系，发表于 *Applied Soft Computing* 第 203 卷（2026 年），文章号 116252，DOI `10.1016/j.asoc.2026.116252`。论文方法、原始实验设计与实验结论均由该文作者完成。

本仓库。 `Alastair-Jiang/DeReFusion`，是一条独立研究分支。仓库自述文件明确写明：本项目是基于公开的 DeReFusion 代码与 THUML Time-Series-Library 代码建立的独立研究分支，不是论文作者发布的官方代码包。代码骨架沿用 THUML 的 Time-Series-Library（因此具有 `run.py`、`exp/`、`data_provider/` 的目录结构）。

本机产物。 本地 `results/` 目录下的 174 项与 `checkpoints/` 下的 175 项结果，覆盖 47 个资产，在 CPU 环境下运行产生，是本机独有的原始产物，未随远程仓库发布。

B. 依据与快照

本报告的全部事实依据来自 GitHub 仓库 `main` 分支的提交 `87bc113`（2026-10-13 合并），其中自述文件的报告更新日期为 2026-10-10；论文侧的数字取自原文 PDF。仓库此后若有更新，应以仓库最新状态为准。

C. 本文性质与边界

本报告是术语与方法层面的说明文本，不是实验报告。它不发布任何数据集、预测数组或权重，也不构成对真实数据访问、预处理、拟合或评分的授权。仓库中的实验结果解释必须绑定各自的协议、清单、日期与尝试身份；较新的文件名不取代既往的批准或预注册。文中所有对结果的引用均保持原报告给定的证据等级，不作升级。

II. 问题设定、数据与切分

A. 预测任务

OHLC. 开盘价（Open）、最高价（High）、最低价（Low）、收盘价（Close）四个字段。模型读取四个字段（`enc_in=4`、`dec_in=4`），只预测收盘价一列（`c_out=1`，参数 `--target Close`）。数据位于 `dataset/` 与 `data/raw/yahoo/`，注册表 `reproduction/results/dataset_registry.csv` 列出 61 个日频 CSV、合计 149 474 行。

时间序列预测与长期预测. 长期预测在此不指预测期很远，而是指一次预测多个未来时间步。运行入口为 `run.py --task_name long_term_forecast`，训练与评估循环位于 `exp/exp_long_term_forecasting.py`。论文覆盖 $T \in \{1, 7, 12, 24, 36\}$，仓库的 Phase 1 收窄为 $\{1, 24\}$。

窗口参数. `seq_len` 为输入窗口长度，`pred_len` 为预测窗口长度，`label_len` 为解码器使用的历史长度。

本模型不使用解码器：DeReFusion 的前向函数直接忽略 x_dec、x_mark_dec 与 mask，只读取 x_enc。默认配置为 seq_len=96、label_len=48、pred_len=24。

资产与分组. Phase 1 共 30 个资产，分为 original-10 与 c1-20 两个确认性分层。两层在任何报告中均须分别报告，不允许用单一合并平均值掩盖分层差异。

非平稳性. 论文以 KPSS 检验报告 10 个资产在 1% 显著性水平下全部拒绝平稳；序列呈现波动率聚集，Hurst 指数约为 0.5，接近随机游走。这是" 回看窗口越长误差越大" 这一结论的背景。

B. 数据切分与两种归一化的分工

时间切分. 时间序列必须按时间先后切分，不得打乱。论文按 70%/10%/20% 顺序切分；仓库的预注册提供两种模式：按比例，或按日期（--split_mode dates 配合 --train_end、--val_end、--test_end，边界为开区间）。审计脚本 reproduction/analysis/audit_phase1_date_splits.py 检查全部 72 个（资产 × 年份 × 期限）组合。

数据泄漏. 指未来信息进入训练或模型选择，使指标虚高。常见形式为打乱时间顺序切分，以及使用全样本统计量拟合归一化参数。冻结方案要求按时间切分，且标准化器仅用训练段拟合。

Z-score 标准化与 RevIN 的分工. 两者作用尺度不同。Z-score 在整份数据上以训练段的均值与标准差缩放一次，实现在 data_provider/ 的数据加载器中；RevIN 在每个输入窗口内以该窗口自身的均值与标准差缩放，预测后再还原，实现在 layers/RevIN.py。教条 L4 要求所有动态变换仅在训练前缀上拟合，即针对此类泄漏。

C. 数据质量的公开处理原则

已知缺陷. 两类问题被公开记录而非静默修复：其一，五份外汇数据存在 OHLC 包络不一致（最高价低于最低价一类）；其二，WTI 原油保留了 2020 年 4 月的非正价格。处理规则是保留原始数据，不允许通过加常数或删除行加以掩盖；涉及对数运算的指标须将这些窗口标记为未定义，而不是修改价格。相关文件为预注册第 2 节、自述文件第 5 节及 reports/evidence_closure/15_data_acquisition_diagnosis.md。

校准专用资产. BOND10Y、BONDETF、CITICSEC 三个资产仅用于校准流程，永远不得进入 Phase 1 的任何结果。

III. 模型架构与公式解读

本节给出代码库中可直接对应到实现的计算式，并说明其数学含义与实现细节之间的关系。所有公式均按 GitHub main 分支的实际代码写出。

A. 总体数据流

DeReFusion 由两条并行分支构成，整体包裹在可逆实例归一化之下，两条分支的输出直接相加：

$$\hat{Y} \;=\; \mathrm{RevIN}^{-1}\big(\, Y_{\text{base}} \;+\; Y_{\text{res}} \,\big), \tag{1}$$

其中 Y_{base} 为 DLinear 基础分支输出，Y_{res} 为非线性残差分支输出，二者形状相同，均为 $[B, T, C]$，B 为批大小，T 为预测长度，C 为通道数。(1) 中的加法不含任何可学习参数。

a) 要点: 该式表明，本项目被比较的对象并非某一分支，而是" 融合算子" 本身。原论文亦明确将 DeReFusion 定位为受控试验台：架构、数据与协议固定，仅融合算子变化。

B. 移动平均分解

趋势分量由滑动平均给出，边界采用复制填充；季节分量定义为原序列减去趋势：

$$X_{\text{tr}}[t] = \frac{1}{k}\sum_{i=-p}^{p} X_{\text{pad}}[t+i], \qquad p = \left\lfloor \frac{k-1}{2} \right\rfloor, \tag{2}$$

$$X_{\text{se}} \;=\; X - X_{\text{tr}}. \tag{3}$$

实现位于 layers/derefusion_components.py 的 MovingAvg 与 SeriesDecomposition：前者以 nn.AvgPool1d 加两端复制填充实现，后者返回 (x - trend, trend)。默认核宽 $k = 25$，通过 getattr(configs, "moving_avg", 25) 读取。

a) 要点: 移动平均是低通滤波器，而非" 趋势的证明"。核宽 k 定义了" 什么算慢"：窗口内的波动归入季节分量，窗口外的变化归入趋势分量。因此分解是**尺度相对**的，改变 k 即改变两个分量之间的分界，$k = 25$（约一个交易月）是可调的建模选择，不是自然常数。此外，(3) 中的" 季节" 分量并不含周期性含义，它只是趋势的补集。

C. DLinear 基础分支

两个分量各自经过一个线性映射后相加：

$$Y_{\text{base}} = W_{\text{se}}^{\top} X_{\text{se}} + W_{\text{tr}}^{\top} X_{\text{tr}}, \qquad W_{\text{se}}, W_{\text{tr}} \in \mathbb{R}^{L\times T}, \quad (4)$$

其中 L 为输入长度，T 为预测长度。实现位于 `DLinearBranch`：分量先置换到 $[B, C, L]$，各自通过 `nn.Linear(seq_len, pred_len)`，再相加并置换回 $[B, T, C]$。

a) 要点： 将 W_{se} 与 W_{tr} 分离，意味着不同时间尺度的分量各自拥有映射，趋势的缓慢演化与季节分量的周期振荡无需共享权重，从而在结构上降低了模式之间的相互干扰。需要同时指出一个易被忽略的实现差异：`DLinearBranch` 使用**通道共享**的线性映射，不含逐通道独立（`individual`）开关；而作为主对手的 `revin-DLinear` 支持独立通道模式，并将线性层权重初始化为 $1/L$ 的常值，DeReFusion 的线性分支则保留 PyTorch 默认初始化。这一初始化的差别在后续消融实验中被证明具有实质影响（见 §VI）。

D. 可逆实例归一化

设窗口 x 在时间轴上的均值与标准差为 $\mu(x)$、$\sigma(x)$，则归一化与反归一化为

$$\tilde{x} = \frac{x - \mu(x)}{\sqrt{\sigma^2(x) + \epsilon}} \cdot \gamma + \beta, \quad (5)$$

$$\hat{y} = \Big(\tilde{y} - \beta\Big)/\gamma \cdot \sqrt{\sigma^2(x) + \epsilon} + \mu(x). \quad (6)$$

实现位于 `layers/RevIN.py`：均值与标准差在时间轴上按 $(B, 1, C)$ 形状计算并被 `detach`，随后存储在模块上；反归一化复用同一组统计量，默认 `affine=True`。

a) 要点： ”可逆” 的确切含义在于 (6) 复用了 (5) 阶段存储的 $\mu(x)$ 与 $\sigma(x)$，而**不是**对预测结果重新计算统计量。这一设计使模型在统一尺度上建模的同时，输出仍处于原始价格尺度；也正是它使得不同资产之间可以比较。所有对手模型同样套用该外壳（即文件名统一的 `revin-` 前缀），这是保证受控比较的一个组成部分。

E. 非线性残差分支

残差分支为一条级联结构，其组合顺序为

$$Y_{\text{res}} = W_o\Big(W_\tau\big(\text{Trans}(\text{LSTM}(W_e\tilde{x}))\big)\Big), \quad (7)$$

其中 $W_e : \mathbb{R}^C \to \mathbb{R}^d$ 为特征投影，LSTM 为单层、隐层宽度 d，`Trans` 为单层 Transformer 编码器（H 头、前馈宽度 $4d$、dropout 0.3），$W_\tau : \mathbb{R}^L \to \mathbb{R}^T$ 作用于时间轴，$W_o : \mathbb{R}^d \to \mathbb{R}^C$ 为通道投影。

a) 要点（”残差”一词的两义性）： 这是本项目最容易误述的一处，必须区分两种用法。就代码实现而言，残差分支是一个与线性分支并行的、独立参数化的预测头：它自行学习一套参数，输出与 Y_{base} 形状相同的张量，随后与 Y_{base} 相加，其性质是” 两个预测头相加”，而非数学意义上的残差拟合。就论文分析而言，原文第 4.5.3 节另给出残差的定义 $r = y - \hat{y}_{\text{lin}}$（线性分支未解释的真实残差）以及非线性分支的净贡献 $\hat{r} = \hat{y}_{\text{full}} - \hat{y}_{\text{lin}}$，用以检验后者是否在学习前者。两者不可互换：前者是模型结构，后者是事后归因分析。此外，代码顶层文档字符串将该分支称为”TransformerLSTM”，而实际执行顺序是 **LSTM 在前、Transformer 在后**，引用时应以 (7) 为准。

F. 融合算子与门控变体

无参数加性融合即 (1)。三个门控变体共用同一形式：

$$g = \sigma\big(A(x) + b_0\big), \qquad Y = (1-g)\odot Y_{\text{base}} + g \odot Y_{\text{res}}, \quad (8)$$

其中 $(1-g)$ 与 g 构成凸权重，b_0 为偏置参数，初值 -2.0，σ 为 sigmoid 函数。三个变体的区别仅在于 $A(\cdot)$：

- **v1 波动率感知**（`DeReFusion-gatev1-volatilityaware.py`）：A 以原始输入的波动率为输入，$\text{std}(x_{\text{raw}}) + 10^{-5}$ 形状为 $[B, 1, C]$，经 `Linear(1, pred_len)` 展开到 $[B, T, C]$。*在本库中：* 该路径将整个窗口的波动信息压缩为每通道一个标量，信息瓶颈显著。
- **v2 可学习**（`DeReFusion-gatev2-learnable.py`）：$A \equiv 0$，$g = \sigma(\alpha)$，α 为形状 $[1, 1, C]$ 的参数初值 -2.0。*在本库中：* 该门控**与输入完全无关**，对每一个样本、每一个时间步给出同一组权重。
- **v3 输入条件**（`DeReFusion-gatev3-inputconditioned.py`）：$A(\tilde{x}) = W_2\,\text{ReLU}(W_1\tilde{x})$，$W_1 \in \mathbb{R}^{L\times m}$，$W_2 \in \mathbb{R}^{m\times T}$，瓶颈 $m = 4$。*在本库中：* 这是三者中唯一真正逐样本、逐通道、逐时间步的条件门控。

a) 要点: (8) 给出了三条可由公式直接读出的推论。第一，偏置初值 $b_0 = -2$ 对应初始门值 $g = \sigma(-2) \approx 0.119$，即训练开始时约 88% 的权重归于基础分支；论文实测的平均门值为 $0.123 \sim 0.140$，与初值几乎相同，说明门控在训练中**基本未被激活**。第二，v2 的门值不含输入变量，在数学上等价于为加法配一个可学习的全局标量权重，逐样本自适应性为零，" 可学习门控" 在此退化为一常数。第三，(8) 是凸组合，因此门控在结构上只能重新分配两条分支之间的权重，无法表达加法之外的任何组合方式。论文报告的直接相加在 50 个（资产 × 期限）设定中胜出 45 个，与上述三点一致。

G. PyTorch 作为实现载体

本项目的主要语言与框架为 Python 与 PyTorch。所有模型定义在 `models/` 下，均为 `nn.Module` 子类：线性层为 `nn.Linear`，循环网络为 `nn.LSTM`，注意力为 `nn.TransformerEncoder`，损失函数为 `nn.MSELoss()`。训练与评估循环位于 `exp/exp_long_term_forecasting.py`，统一入口为 `run.py`；依赖按功能分为三组置于 `requirements/` 下（核心、CUDA 版、可选基础模型）。

归纳偏置. 模型先天假定的结构假设。DLinear 假定序列大致可线性外推，Transformer 假定任意两个时间点之间可能存在关系。论文的核心结论之一是：其优势来自与序列结构相匹配的归纳偏置，而非增加的容量。

神经网络. 由多层神经元堆叠、通过反向传播与梯度下降拟合参数的模型族。本项目训练细节为：损失函数 MSE、优化器 Adam、学习率 10^{-4}、批大小 32、最多 30 轮、按验证集早停（耐心值 5）。残差分支即为该模型族在本项目中的具体形态，其必要性由消融实验检验。

冻结训练协议. 预注册固定了统一训练设置：`seq_len=96`、`label_len=48`、`enc_in=4`、`dec_in=4`、`c_out=1`；`d_model=32`；移动平均核宽 25；Transformer 为 8 头、2 编码层、1 解码层、`d_ff=2048`、dropout 0.1；Adam、学习率 10^{-4}、MSE 损失、cosine 调度；最多 30 轮、耐心值 5、按验证集选检查点；明确不做模型专属超参数搜索。

随机种子. `run.py` 提供两个不同参数：`--rand_seed`（默认 2021，用于随机数播种）与 `--seed`（默认 2，仅用于数据增强）。预注册规定：校准与筛查用 $\{2021\}$，主配对用 $\{2022, 2023, 2024\}$，时间稳健性用 $\{2024\}$。其中筛查阶段的种子 2021 被排除在主估计之外，因为其结果已被观察。

早停. 连续 5 轮验证集指标未改善即停止，取验证集最优检查点，最多 30 轮。

IV. 对手模型体系

A. *revin-* 前缀的含义

仓库中 10 个 `models/revin-*.py` 文件统一带此前缀，表示在同一骨干网络外统一套用与 DeReFusion 相同的可逆实例归一化外壳。这是受控比较的组成部分，用于消除归一化差异带来的干扰。

B. Phase 1 实际运行的模型

预注册的模型清单为五个：`revin-DLinear`、`DeReFusion`、`revin-PatchTST`、`revin-iTransformer`、`revin-TimesNet`。

revin-DLinear. 主对手。$Y = W_{\text{se}}^{\top} X_{\text{se}} + W_{\text{tr}}^{\top} X_{\text{tr}}$ 的线性分解模型，权重初始化为 $1/L$。Phase 1 的 Stage C 即 DeReFusion 与该模型的配对比较。

revin-PatchTST. 将序列切分为若干 patch 作为 token，逐通道独立建模。

revin-iTransformer. 将变量维度作为 token，注意力作用于通道维。

revin-TimesNet. 将一维序列折叠为二维周期张量，以二维卷积提取周期结构。论文报告其参数量为 2355.5k，约为 DeReFusion 的 90 倍，而精度处于同一水平。

C. 论文中的基准家族

论文比较了 10 个基准，这些文件的模型定义均在仓库中存在，但不属于 Phase 1 的运行清单：DLinear、LightTS、ETSformer、PatchTST、iTransformer、Informer、Reformer、FEDformer、Autoformer、TimesNet。论文给出的平均秩为：ETSformer 3.12、DeReFusion 3.18、TimesNet 3.20、PatchTST 3.58，四者统计上不可区分；Informer、Reformer 等重型注意力模型被 DeReFusion 显著超过（Friedman $\chi^2 = 357.08$，$p < 0.001$；Nemenyi 临界差 $\text{CD} = 2.14$）。

D. 零样本基础模型与声明缺口

零样本基础模型. `models/Chronos.py`、`models/Moirai.py`、`models/TimesFM.py`，需单独安装可选依赖

（requirements/foundation.txt）。其特点是不做任何训练直接用于预测，与上述所有" 每个资产重新训练" 的模型不属于同一比较体系，不可并入同一排名。论文报告中三者统计精度更优。

声明缺口. 预注册列出 declared_gaps：TimeMixer 与状态空间模型（Mamba）。layers/MambaBlock.py 存在，但未接入比较。

通道共享与通道独立. OHLC 含 4 个通道。通道共享指四通道共用同一组线性权重，通道独立指每通道各自一组权重。DeReFusion 使用前者，revin-DLinear 支持后者。

V. 评估指标与统计判定

A. 指标体系

误差指标. MSE、MAE、RMSE、R^2、MAPE。主指标与损失函数均为 MSE（nn.MSELoss()，见 exp/exp_long_term_forecasting.py）。论文在 $T = 1$ 时报告 MSE 为 0.037、R^2 为 0.948。不同资产、不同期限的 MSE 不可不加说明地直接比较。

方向准确率. 仅判断涨跌方向是否正确，随机猜测的基准为 50%。论文报告为 50.82%。

夏普比率与买入持有. 夏普比率衡量单位波动所对应的收益，属于风险调整后的效率指标；买入持有指不做任何交易、长期持有的基准策略。论文报告：零成本时夏普为 0.26，加入 10 个基点交易成本后降至 -0.35；同期买入持有夏普为 0.62、年化收益 17.77%。

B. 配对比较与分层

主比较量为 $\Delta\text{MSE} = \text{MSE(DeReFusion)} - \text{MSE(revin-DLinear)}$，负值表示 DeReFusion 误差更小。该量按分层 × 期限 × 种子分别报告，共 12 个分层点估计。当前状态：$T = 1$ 各层全为负；$T = 24$ 出现跨零甚至转正（例如 original-10、$T = 24$、种子 2023 为 $+0.004682$，种子 2024 为 $+0.000922$）。

分层. original-10 与 c1-20 两层在任何报告中均须分别报告。预注册原文为：" 不得以单一合并平均值掩盖两个分层。"

C. 统计检验族

Friedman 检验. 针对多模型多设定情形的整体排名检验。论文结果 $\chi^2 = 357.08$，$p < 0.001$，表明模型间存在系统性差异。

Nemenyi 检验. Friedman 之后的两两比较，给出平均排名差的临界值，论文中 CD = 2.14，据此判定哪些模型之间统计上不可区分。

Wilcoxon 符号秩检验. 配对非参数检验，用于比较两模型在同一配对上的差值分布。

Diebold–Mariano 检验. 预测学中的标准工具，专门用于比较两个预测序列的误差。

三者在本项目中被并用，用于复核结论不依赖于某一种检验方法。

D. 多重性、选择过拟合与试验次数

Holm 校正. 在同族内进行多组两两比较时收紧显著性门槛，抵制成对比较带来的偶然显著性。预注册承诺在 Stage B 的现代模型族内实施该校正；此前核查未在仓库中找到对应实现，引用前建议重新核实。

选择过拟合、PBO 与 CSCV. 若在大量候选中挑选表现最佳者，其最优表现中包含运气成分。PBO（回测过拟合概率）量化该成分，CSCV（组合对称交叉验证）是其估计方法。教条 L4.8 规定：" 高于 0.05 是拒绝，不是注意事项。"

试验次数 N. 原则 P4 要求：N 在首次运行前确定并声明，每个种子计为一次试验；事后须如实报告，并对胜者附缩水表。没有 N 的结果" 不可解释"。文件同时承认一处缺口：缩水表机制是为夏普类选择准则推导的，不适用于误差类指标协议，因此试验次数目前属于未校正的注意事项。

bootstrap 置信区间. 预注册要求以固定种子、等权重的资产聚类 bootstrap 估计区间。但种子值、重抽样次数、区间算法以及跨期限与跨种子的汇总规则均未事先冻结，因此确认性区间目前无法计算，Stage C 的结论只能停留在描述性层面。

E. 预注册与三条允许结论

预注册与协议号. 文件为 docs/PHASE1_PREREGISTRATION.md，协议号 phase1-v1.1-2026-09-19，在任何 Phase 1 结果产生之前冻结。

三条允许结论（原文）该研究只允许支持以下三条中的一条：

1) **一致性收益**：DeReFusion 在两个冻结资产分层中的配对损失差均为负，聚类 bootstrap 95% 区间不含零，且成本增加未压倒精度增益；

2) **条件性收益**：合并区间或某一分层跨过零，但事先声明的资产/期限汇总显示出可重复的异质性；
3) **无优势证据**：上述条件均不满足。

第 3 条亦是合法结论，写出不构成失败。随后紧接一句禁令：任何结果均不授权资产级路由器、不授权抢救 |ACF1|、不授权物理或 Navier–Stokes 机制主张。

禁令清单. 不得事后进行特征搜索；不得声称波动率越高越应选择非线性算子；不得复活样本级门控、路由器或混合专家；训练中不得使用测试损失或人工挑选模型；不得以单一合并成绩掩盖资产、种子、期限层面的失败；在未给出可测量物理约束的前提下不得使用”物理启发”” 守恒””Navier–Stokes” 等表述；不得因某资产符号不便而删除该资产。

VI. 消融实验全流程

A. 消融的定义与判定逻辑

消融指逐次移除模型的一个组成部分，观察性能变化：移除后显著变差说明该组件有效；无变化说明该组件无实质贡献；反而变好说明该组件产生负作用。其逻辑前提是控制其余条件不变。需要强调的是，” 执行了消融” 与” 证明了组件必要性” 是两件不同的事，本项目的证据矩阵对二者分别标注。

B. 论文中的消融设计

论文消融包括四个变体：完整模型、移除 LSTM、移除 Transformer、移除整条非线性残差分支（仅保留 DLinear 基础分支）。除被移除的组件外，其余骨架、预处理、切分、回看长度 $L = 96$、五个期限、五个随机种子与超参数全部一致。

论文由此得出三条结论。第一，非线性残差分支在短期限贡献最大：$T = 1$ 时完整模型误差 0.037，相对仅保留线性分支的 0.051 降低约 27%。第二，LSTM 与 Transformer 互补，且短期限 Transformer 更重要：$T = 1$ 时移除 Transformer 退化到 0.047，幅度大于移除 LSTM 的 0.041。第三，长期限由线性基础分支主导，残差分支的增益消退甚至反转：自 $T \geq 12$ 起移除 LSTM 反而取得最优，$T = 36$ 时完整模型垫底（0.295，劣于移除 LSTM 的 0.284 与移除残差分支的 0.285）。

原文同时声明：” 在本次测试的架构内，线性基础分支承担了大部分长期限性能，额外的非线性容量贡献很小，甚至可能降低精度。本次消融并未隔离机制；循环 LSTM 的误差累积是可能的原因之一。” 该声明限定了结论的适用范围。

关于” 移除残差分支” 与独立 DLinear 的关系，论文指出二者预测的相关系数为 0.999，但数值并不相同（移除残差分支在 $T = 1$ 为 0.051，独立 DLinear 为 0.049）。这一微小差异在仓库侧被证明具有实质影响，见 §VI-E。

C. 残差互补性分析

为检验非线性分支是否在学习线性分支未解释的部分，论文定义真实残差 $r = y - \hat{y}_{\text{lin}}$ 与非线性分支净贡献 $\hat{r} = \hat{y}_{\text{full}} - \hat{y}_{\text{lin}}$，在同一批对齐窗口上计算。

a) 要点: $T = 1$ 时相关系数为 0.522、斜率为 1.029（接近无偏，说明量级亦匹配）、误差降低 27.4%，表明该分支确实在学习线性分支无法覆盖的残差动态，而非提供冗余容量。但随着期限增加，对应关系单调减弱：到 $T \geq 24$ 时相关系数仍为正，而净误差降低转为负值，斜率降至 0.5 以下，说明其贡献消退并可能转为干扰。

D. 融合算子与回看长度的对照实验

融合算子. 在固定架构下仅替换融合算子，覆盖 50 个（资产 $\times$ 期限）设定。直接相加在 $T = 1$ 为 0.037，优于可学习门控的 0.049、输入条件门控的 0.052 与波动率感知门控的 0.054；在 50 个设定中胜出 45 个。复杂度递增伴随退化递增（平均 MSE 依次为 0.147、0.156、0.158、0.159）。学到的门值持续偏向基础分支：平均门值 $0.123 \sim 0.140$，测试样本中门值超过 0.5 的比例至多 0.04%，无一超过 0.9。此外，门控表现为**欠拟合**而非过拟合：门控训练损失 $0.040 \sim 0.041$，直接相加为 0.037；泛化间隙分别为 0.018 与 0.019。

回看长度. $L \in \{48, 96, 192\}$。$T = 1$ 时 MSE 分别为 0.036、0.037、0.087；五期限平均 MSE 由 0.133 升至 0.147 再升至 0.227。结论为：回看窗口越长误差越大，与弱长期记忆一致。重型注意力模型在 $L = 192$ 时性能崩溃，而 DeReFusion 平均 MSE 上升约 71%，R^2 仍高于 0.42。

论文未执行的消融. 该文未做归一化开关消融、分解开关消融与 dropout 或容量扫描。作者在局限部分明确说明两点：其一，级联顺序（LSTM 前置）相对于并联结构或纯注意力的优劣” 未在此处消融，因此属设计选择而非已验证的最优配置”；其二，本研究刻意采用轻

表 I
论文消融结果：MSE（10 资产 × 5 种子）

变体	$T=1$	$T=7$	$T=12$	$T=24$	$T=36$
完整模型（DeReFusion）	**0.037**	**0.081**	0.117	0.205	0.295
移除 LSTM	0.041	0.083	**0.116**	**0.197**	**0.284**
移除 Transformer	0.047	0.082	0.116	0.204	0.293
移除残差分支	0.051	0.093	0.127	0.203	0.285

表 II
残差互补性：$\hat{r}$ 与 r 的对应关系

指标	T=1	T=7	T=12	T=24	T=36
相关系数	0.522	0.349	0.294	0.159	0.099
误差降低	+27.4%	+12.2%	+8.1%	−0.3%	−3.4%
OLS 斜率	1.029	0.954	0.798	0.480	0.311

表 III
仓库侧消融与相关对照的判定

项	结果与判定
组件消融重跑（6 次，第二台机器，单种子 2021，协议相同）	环境校准复现（0.070065 对 0.07007）。移除 Transformer 比完整模型差 10.71%；移除 LSTM 在 GSPC 上比完整模型好 1.29%；BTCUSD 三个变体均劣于完整模型。判定：**部分支持**——组件必要性未确立（仅单种子、两资产）。
移除残差分支消融的有效性	该变体在架构上与 `revin-DLinear` 完全相同（4664 参数），却相差 8.28%，追溯至权重初始化约定（$1/L$ 常值对 PyTorch 默认）。判定：**不支持**（`CONFOUNDED_BY_INIT`）——不能解释为组件移除效应。
跨机器复现基线	另一台独立配置机器复现 GSPC $T=24$ 的 `revin-DLinear` 校准（0.070065 对 0.07007）。判定：**支持**。
门控对照	GSPC 上 v1 门控 0.06767，直接相加 0.06230。判定：**不支持**。

量且与模型无关的可逆实例归一化，未纳入更精细的自适应归一化方法。上述内容在对外陈述时应如实转述。

E. 仓库侧的重跑与判定

仓库对消融做了独立重跑，并按证据等级逐条判定。

T=24 的 GSPC 结果排序为：DeReFusion（0.0623）< DLinear（0.0701）< gatev2 可学习门控（0.0719）。

F. 容量与路由

容量敏感性实验. 仅改变非线性算子的隐藏宽度（23/64/128），其余条件完全相同。ΔMSE 为负表示非线性更优：

三个资产给出三种不同结论：ETHUSD 在容量足够时全面转向非线性；GSPC 随容量增大趋近打平；BTCUSD 在所有容量下均偏好线性且差距扩大。判定为容量敏感（ETHUSD 高、GSPC 中、BTCUSD 无）。相关规定要求采用更审慎的表述：不得将” 线性更优” 整体归因于表示瓶颈，能支持的较弱表述是” 容量敏感性是当前证据中的主要不确定性或混淆因素”；宽度 23 下 ETHUSD 的结果不构成” 非线性算子无用” 的证据，只说明该容量对该资产不足。

路由实验. 12 个预先登记的结构状态、容量对齐的算子、三个种子。GSPC 与 BTCUSD 在全部 12 个状态下均偏好线性；ETHUSD 在宽度不小于 64 时 12 个状态同时翻转，属资产级差异而非状态级差异。跨状态散布随容量收缩，逐种子方向一致性随容量下降（31/36 至 28/36）。判定为：无可靠的样本级路由证据。

G. 小结：为什么” 执行完成” 不等于” 支持假设”

本项目用四类实证说明这一区分。其一，样本不足不足以支撑结论：组件消融重跑仅单种子、两资产，只能判为部分支持。其二，实现细节会污染消融：架构相同的两个变体因初始化不同而相差 8.28%。其三，容量未被控制时会成为混杂因素：容量改变即足以令结论方向翻转。其四，消融只能说明” 在本架构内”，不能说明原理层面的必要性，论文与仓库均就此作了明确限定。此外，仓库规定：当估计量有符号而区间跨零时，只能表述为” 方向性如此、统计上不可判”，不得升级为” 支持”。

综合论文与仓库两侧证据，非线性计算的价值是**条件性**的，即取决于资产、容量与市场条件，不存在任何一个资产上” 永远且处处” 更优的非线性分支。

表 IV
容量敏感性：ΔMSE 与偏好非线性比例

宽度	参数量	GSPC	BTCUSD	ETHUSD
23	9 431	+0.05982 (0/36)	+0.17832 (0/36)	+0.01454 (12/36)
64	26 200	+0.02503 (7/36)	+0.18884 (0/36)	**−0.02807** (36/36)
128	52 376	+0.00606 (8/36)	+0.29983 (0/36)	**−0.03205** (36/36)

VII. 实验治理：六层卡口与授权制度

A. 四条原则

P1 一个数字一个出处. 每个报告的数字须可追溯到产物哈希及其生成配置。

P2 先断言再执行、如实记分. 每个卡口记 1 分（自动化且可重复）、0.5 分（人工执行且结果有文档）、0 分（缺失或失败）；一个阶段的得分取该阶段各卡口组的**最低分**，而非平均分。这意味着阶段内任一缺失即导致该阶段不能通过。

P3 每次偏差都须产出断言. 偏差记录若以处置收尾而未新增检查，则视为未完成。

P4 试验次数属于结果的一部分. N 须事先声明并如实报告，胜者附缩水表。

B. 六层卡口

层间关系有一条规定：上层不得用于修改 L0 或 L1 的判定。

事故索引 I1–I7. 上述条款各自对应一次记录在案的事故：I1，某个基线模型参数量达参考实现的 15.96 倍；I2，状态字段与终止字段互相矛盾；I3，根路径配置为空导致 15 次拟合被错误编号为同一尝试；I4，一次静默的 `nanmedian` 丢弃 96 个窗口；I5，五份外汇数据的 OHLC 违规率 1.1% ∼ 6.4% 未量化；I6，跨平台换行符转换破坏全部冻结哈希；I7，手写的固定样例与冻结配置不一致。

C. 授权、收据与证据闭包

协议与尝试的状态机. 协议状态：起草、已复核、设计已批准、阶段已放行、关闭或取代。尝试状态：已计划、已开始、已完成未复核 / 失败 / 中断、已验证 / 已拒绝。文件特别指出：目录数、收据数与不同文件哈希数均不是独立实验数量。

执行授权. 见 `docs/management/v1_4/AUTHORIZATION.md`。设计通过不等于允许处理真实数据。授权文件须写明决策人、时间、仓库与提交身份、协议与源码哈希、数据契约、允许的阶段与输入根目录、输出目录、设备与预算、失败处理与撤销条件。次序为：数据资格授权、预处理授权、拟合授权、评估授权。真实数据访问当前处于关闭状态。

收据. 每次运行生成不可篡改的元数据记录，字段包括逻辑运行标识、尝试序号、尝试标识、被替代尝试、重试原因与重试授权、创建时间、协议版本、冻结提交、配置指纹、数据哈希、完整命令、环境指纹、数组形状、有限性检查、诊断信息与逐文件哈希。核对结果为：729 条记录中 728 条可唯一对应一个计划行，覆盖 675 个不同计划行；另有 5 个字节完全相同的隔离副本不计为新尝试；699 条处于” 已完成未复核” 状态。

重试. 重试须新建尝试并记录被替代对象与原因，不得覆盖既有检查点或日志，不得挑选最优一次而隐藏其余失败。明确规定” 因效果不佳不得重试”，仅技术性失败可重试并须另发重试授权。

四层验收. 运行完成、产物接收、结构验收、科学可用为四个独立字段。结构验收检查文件完整性与身份；数值验收须另有授权，检查共同键、真值一致性、尺度、指标重算与非有限输出；研究验收再检查预注册、测试暴露与主张范围。文件明确：” 合成测试不证明真实泛化，哈希匹配不证明算法正确。”

证据闭包. `reports/evidence_closure/` 下编号 00 至 29 的结论账本，只可追加、不可改写。否定结果、执行异常与已冻结决定均作为证据保留。

数据权利审查. `docs/DATASET_RIGHTS_REVIEW_V1_2026-10-10.md` 与配套的 61 行台账，覆盖 61 份 OHLC 数据。当前所有权利状态仍待核实；向外部提供数据或结果前必须逐项审阅。

D. 滚动轮次之间的验证污染：*L5* 的一处缺口

在滚动评估中，第 1 轮的测试区间会在第 2 轮成为验证区间。设第 1 轮为训练 20–21、验证 21–22、测试 22–23，第 2 轮为训练 21–22、验证 22–23、测试 23–24，

表 V
实验教条 L0–L5 的分层与关键条款

层	所回答的问题	关键条款
L0 输入资格	数据本身是否合格	内容哈希在消费时校验；时间网格须声明；跨序列可比仅允许一种事先声明的机制；**禁止静默删除 NaN**（以跳过 NaN 的归约函数实现删除同样构成删除）；缺陷处理须在结果产生前声明
L1 实现保真	运行的确实是指定基线吗	每个模型须指明参考实现与配置并逐行比对超参数；进行容量量级检查；偏离参考超过约定倍数者” 不再是该基线”；L1.8：” 对冻结配置的检查必须读取那份冻结配置”
L2 校准	机器能否跑通	**本层不产生任何科学主张**；损失不排名、不发布；状态字段与终止字段不得矛盾；设备中途更换属协议事件
L3 筛查	大范围筛选	评估键须在模型运行前生成；存在反馈回路时最终评估须封存（实证损失：最佳提交 63.7% 胜基准，选中提交 48.4%，差 15.3 个百分点）
L4 确认	主结论的唯一来源	估计量、分层与汇总规则须先于结果声明；活跃的确认协议不得修改，变更须启用新协议号；试验次数为声明而非事后统计；胜者附缩水表；选择过拟合以 CSCV 估计，阈值 0.05；每个卡口须指明有资格满足它的主体
L5 时间稳健性	换时间段是否成立	滚动切分采用明确的开区间日期边界；固定比例切分不得改称滚动原点评估；每段仅可借用前序 `seq_len` 行；事后敏感性分析标记为探索性

则 22–23 区间在第一轮已作为测试集被观察，第二轮又作为验证集参与早停与配置选择。此时数据本身没有串通，但**研究者的判断已经携带了该区间的信息**，验证集失去独立性，无法再承担” 何时停止训练” 与” 选择哪个配置” 的职责。

这与通常意义的数据泄漏不同：后者是数值进入训练，可通过清除与禁运处理；前者是判断进入流程，在数据层面无法检出。

本仓库的现状. L5.1–L5.4 四条分别涉及日期边界、命名规范、输入上下文借用与前向敏感性分析，*均未涵盖该问题*。教条中两处最接近的条款亦不能替代：L3.4 关于反馈回路的原则方向一致（其引用的实证损失为 15.3 个百分点），但其表述针对” 开发期观察到分数” 这一类回路，未点明滚动轮次这一形态；L4.9 的清除与禁运针对同一次切分内的标签区间重叠，且仓库已核实该条由构造即满足（`Dataset_Custom` 将可用区间计为 $\text{len} - \text{seq_len} - \text{pred_len} + 1$，标签不越界），因此它处理的是数值而非判断。

该问题并非假想。 Stage D 的设计即为：对测试年 Y，训练截至 $Y-2$ 年末，验证使用 $Y-1$ 年，测试使用 Y 年，测试年为 2023、2024、2025。代入可得，2023 年那一轮的测试年，在 2024 年那一轮成为验证年。Stage D 目前执行进度为 0/144，尚未运行，因此在该阶段启动前补充规则的成本最低。预注册中已出现” 滚动切分的实现缺口” 这一表述（在 Stage A 产物与该缺口复核之前不授权 Stage B–D 训练），说明该问题已被承认，只是未具体到” 上一轮测试结果的可见性”。

建议的补充方式. 宜挂靠于已有的 L3.4，说明” 滚动轮次之间的测试结果可见性” 是该反馈回路的一种形态，而不宜新立条款。理由是教条 L4.4 的说明部分明确反对把更强的读法当作移植来的要求，那属于发明规则而非移植规则。

VIII. R1 前瞻增量轨道

轨道内容. 协议号 `R1-exploratory-small-panel-20261007-v1`，与 Phase 1 的主要区别在于预测目标：使用 96 行 OHLC 历史预测下一条观测到的收盘价，即单步前瞻。资产为 BTCUSD、ETHUSD、GSPC、N225 四个。设计文件位于本地工作树 `research_work/forward_`

increment/，由 docs/management/v1_4/r1_release_candidate.json 引用。

三条臂. 记作 F、L、B，其中 F 与 L 为主比较，B 与 persistence（朴素持续预测）为辅助。主增益量为 $\mathrm{MSE}(L)-\mathrm{MSE}(F)$。文件特别说明：直接比较 $F-B$ 会同时改变多个因素，因此" 不能单独证明非线性机制"。另设 ridge 作为候选求解器。

流水线与预算. 按顺序通过以下关卡：来源与内部使用依据、保管人质量检查、固定切分与行键身份、F/B 合成生命周期的独立复核、T0 接口负例测试、合成资源检查与可执行清单、拟合放行、验证选择与冻结、评估器放行、全量分层报告。资源上限为：CPU、单并行拟合、2 线程、0 数据进程、神经部分 float32、ridge 与汇总 float64、累计 12 小时、单次神经拟合 30 分钟、付费 0。计划 24 次神经拟合，24×30 分钟恰好占满 12 小时，文件明确指出未为 ridge、评估与汇总预留时间，因此在放行前须以合成计时重新估算，否则须另拟协议修订。

当前状态. 候选文件状态为 DRAFT_BLOCKED，execution_permitted 为 false，签发人与签发时间均为空；四个阶段（保管人检查、预处理、拟合、评估）均为未签发。给出的理由为：存在行政授权，但分阶段的运行证据尚未被接受，候选文件不构成授权。

IX. 复现、命名与边界

A. 可复现性与重复

这两个术语在不同学科约定下含义相反，教条 X7 要求不得静默继承术语。本项目的做法是把结论绑定到" 协议 + 时间 + 可复核产物"，而不是仅提供一个可运行的脚本。自述文件亦说明：仅克隆代码仓库不足以完整重现某项实验，因为大型训练日志、检查点与部分预测产物可能仅保留在运行机器上。

B. 目录名与配置的不一致

run.py 使用 args.n_heads 等参数拼接结果目录名，因此每个结果目录名均标注 dm32_nh8_el2_dl1_df2048。但 main 分支的 models/derefusion/DeReFusion.py 中，DeReFusion 家族走的是源码内定的值：n_heads 默认 4、Transformer 层数固定 1、$\texttt{dim_feedforward}=d_{\text{model}}\times 4$、dropout 0.3；而预注册声明的是 $8/2/2048/0.1$。即：目录名宣称的配置、预注册要求的配置、代码实际运行的配置三者不一致。教条 L1.8" 对冻结配置的检查必须读取那份冻结配置" 正对应此类问题。该问题会使" 两端超参数一致" 这一受控比较的前提不成立，在对外陈述时应主动说明。

C. Navier–Stokes 边界

仓库中有一个以流体力学方程为架构灵感的研究设想。相关规定明确：该设想既未被本仓库验证，也不能说已被本仓库否定。依据为 docs/LITERATURE_AND_NEXT_PLAN.md 第 2.3 与第 4 节、reports/ns_hypothesis_charter.md 及自述文件第 6.3 节。其要点是：OHLC 面板不具备相应的状态变量、守恒量、边界条件或已知的偏微分方程残差，因此不得将"NS 启发" 升级为" 物理启发"，除非能够独立给出可测量的状态、不变量与可证伪的微分约束。失败时的规定表述为" 被测的算子归纳偏置未改善匹配的预测基准"，并明确不得泛化为"Navier–Stokes 在金融中不成立"。

D. 已退休的表述与发布边界

已退休的表述. " 表示瓶颈" 一词被停用，建议至多谨慎使用" 容量假象"，原因是改变宽度会同时改变表示能力、优化、正则、方差与隐式偏置。另一条：同一区段内特征与结果的关系应表述为" 同期且描述性"，不得称为" 泄漏"。

发布边界. 仓库文档明确" 这不是对整个仓库的一揽子放行"。发布实验包之前须逐项审阅数据权利、机密内容、原始与派生数据、凭据、本地路径、检查点与用户改动；受限数据集须留在版本控制之外，仅发布获取方式、模式、版本标识、校验和与转换代码。

X. 覆盖度统计

本报告合并并重写了两份前期文档，术语条目共 82 条。仓库 main 分支已跟踪文件 1563 个，其中 .npy 569、.txt 276、.py 145、.json 135、.md 125、.csv 112、.tsx 63、.pth 48、.log 35。其中数据与权重类文件不计入概念分母，以避免统计口径虚高。

术语条数略多于概念数，原因是部分条目覆盖多个概念，个别概念亦在两处从不同角度各述一次。分母 78 为本报告自行枚举，不是仓库的官方口径。

尚未覆盖的内容主要包括四类：各对手模型的论文原始出处；reproduction/analysis/ 下各分析脚本的逐行说明；data_provider/ 数据加载器的实现细节；research-ops-site/ 前端项目，以及 docs/management/ 下两个大体量 JSON 的逐字段结构。

表 VI
覆盖度统计

口径	分子与分母	占比
概念覆盖	82 条术语（对应约 79 个独立概念）/ 78 个待解释概念（自行枚举）	接近 100%
文件锚点	约 75 个仓库文件与目录 / 270（145 `.py` 加 125 `.md`）	约 28%
文档阅读	约 32 份文档 / `docs/` 下 44 份 `.md`	约 73%

说明

本报告依据 GitHub 仓库 `main` 分支提交 `87bc113`（2026-10-13）整理，论文数字取自原文 PDF；仓库此后若有更新，应以仓库最新状态为准。报告中标注为” 缺口”” 不一致” 的内容，属于依据仓库文档所作的观察，供讨论使用。

参考文献

[1] C.-C. Hsieh and M.-Y. Chen, “DeReFusion: A controlled comparison of soft computing fusion strategies for financial time series forecasting via a decomposition-residual architecture,” *Applied Soft Computing*, vol. 203, art. 116252, 2026, DOI: 10.1016/j.asoc.2026.116252.

[2] THUML, “Time-Series-Library,” GitHub repository. [Online]. Available: https://github.com/thuml/Time-Series-Library